ANALISIS BIG DATA NYC YELLOW TAXI (DESEMBER 2025) DENGAN PYSPARK

Laporan Midterm Project: Struktur Tarif, Perilaku Tip, Pola Perjalanan Jauh, dan Prediksi Tarif Argo Standar

Disusun oleh:

Muhammad Rifky Alfajri - 103012430036

PROGRAM STUDI S1 INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS TELKOM
BIG DATA AND ARTIFICIAL INTELLIGENCE

2026

Ringkasan. Laporan ini menganalisis 4.305.006 catatan perjalanan NYC Yellow Taxi bulan Desember 2025 dengan PySpark (DataFrame API, Spark SQL, MLlib). Setelah cleaning tersisa 3.973.404 baris (92,30%). Temuan utama: (1) persentase tip kartu kredit hampir seragam sepanjang hari (rata-rata 17,13% dari tagihan sebelum tip), dan slot tertinggi (Senin-Kamis 21:00-22:59) tidak dapat dibedakan secara statistik; (2) puncak perjalanan jauh pada sore hari adalah efek rute bandara, bukan pola mobilitas kota; (3) tarif argo standar dapat diprediksi hampir sempurna dari jarak dan durasi oleh regresi linear sederhana (RMSE $1,34; R^2 0,989), lebih baik daripada Random Forest (RMSE $2,72); (4) null *passenger_count* bersifat struktural, bukan acak.

1. Latar belakang dan rumusan masalah

Taksi kuning New York mencatat setiap perjalanan secara elektronik dan datanya dirilis publik oleh NYC Taxi and Limousine Commission (TLC). Data ini cocok untuk latihan analisis data besar: ukurannya jutaan baris per bulan, bentuknya tabular, tetapi mengandung anomali nyata (timestamp di luar periode, jarak mustahil, nilai negatif, dan null sistematis). Desember 2025 juga memuat komponen biaya baru (*cbd_congestion_fee*) sehingga konsistensi pencatatan biaya layak diperiksa.

Pertanyaan utama. Bagaimana struktur tarif, perilaku tip, dan pola perjalanan jauh NYC Yellow Taxi pada Desember 2025, dan seberapa jauh tarif argo standar dapat diprediksi dibanding baseline sederhana?

No	Pertanyaan turunan	Ukuran jawaban
Q1	Pada kombinasi hari dan jam mana median persentase tip pembayaran kartu kredit paling tinggi, dan apakah 5 teratas berbeda secara statistik?	Median dan rata-rata tip%, jumlah trip, interval kepercayaan 95% (minimal 500 trip per slot)
Q2	Ke mana tujuan perjalanan jauh (> 10 mil) pukul 14:00-16:59, dan apakah jam itu puncak perjalanan jauh?	Zona tujuan, share, volume per jam; dengan dan tanpa filter RatecodeID
Q3	Seberapa akurat Random Forest memprediksi *fare_amount* dibanding baseline rata-rata dan regresi linear, dan fitur mana yang berkontribusi?	RMSE, MAE, R^2, RMSE relatif; drop-column importance
Q4	Berapa besar anomali data, bagaimana pola null *passenger_count*, dan berapa retensi setelah cleaning?	Tabel waterfall, pola null per VendorID
Q5	Apakah kolom *extra* dan *cbd_congestion_fee* konsisten dengan aturan tarif TLC?	Distribusi nilai dibanding aturan TLC

Pengguna dan keputusan. Pengemudi/pengelola armada (kapan dan ke mana mengarahkan armada: Q1, Q2); perencana kebijakan TLC/MTA (apakah komponen

biaya, termasuk congestion pricing, tercatat konsisten: Q5); pengembang aplikasi tarif/ETA (apakah tarif dapat diperkirakan sebelum perjalanan: Q3).

2. Karakteristik Big Data (5V)

Aspek	Penilaian	Bukti
Volume	Menengah-besar	4.305.006 baris, 20 kolom, 73,7 MB Parquet terkompresi, 16 partisi, satu bulan. Memenuhi saran ≥ 1 juta baris; di bawah 500 MB mentah.
Variety	Rendah	Tabular terstruktur (numerik, timestamp, kode kategorikal); tanpa teks bebas atau data semi-terstruktur.
Velocity	Rendah	Dirilis TLC sebagai berkas bulanan (batch), bukan aliran. Ukuran besar tidak berarti velocity tinggi.
Veracity	Menengah	27,77% baris null sistematis; jarak maksimum 322.576 mil; fare dan tip negatif; 57.416 baris Vendor 7 dengan dropoff sama dengan pickup; 9 baris di luar Desember.
Value	Tinggi	Mendukung keputusan armada (tip, perjalanan jauh), evaluasi kebijakan tarif, dan estimasi tarif.

3. Data, penyimpanan, dan arsitektur

Provenance. Sumber: NYC TLC Trip Record Data (nyc.gov/site/tlc/about/tlc-trip-record-data.page). Berkas: *yellow_tripdata_2025-12.parquet* dan *taxi_zone_lookup.csv*. Ketentuan: data terbuka NYC Open Data, disediakan publik secara gratis tanpa jaminan kelengkapan atau akurasi. Tanggal akses: 1 November 2026. Data tidak memuat identitas pribadi.

Data dictionary ringkas. Kolom kunci: *tpep_pickup/dropoff_datetime* (waktu), *passenger_count* (diisi pengemudi), *trip_distance* (mil argometer), *RatecodeID* (1 standar, 2 JFK tarif tetap, 3 Newark, 4 Nassau/Westchester, 5 negosiasi, 6 group ride), *PULocationID/DOLocationID* (zona 1-263), *payment_type* (1 kartu kredit, 2 tunai; kode 0 = Flex Fare menurut dokumentasi TLC), *fare_amount* (argo), *extra* (surcharge malam/jam sibuk), *tip_amount* (tercatat otomatis hanya untuk kartu), *congestion_surcharge*, *Airport_fee*,

cbd_congestion_fee (toll MTA zona selatan Jl. 60), *total_amount*.

Pertimbangan	SQL (RDBMS)	NoSQL	Data warehouse	Data lake (Parquet)
Struktur data	Cocok (skema tetap)	Fleksibilitas skema tidak diperlukan	Cocok	Cocok
Pola akses	Transaksional	Lookup key/dokumen	Agregasi analitik	Agregasi analitik, scan

				kolom
Biaya/kompleksitas	Perlu proses load	Tidak relevan	Perlu ETL dan server/lisensi	Rendah; file langsung dibaca Spark

Keputusan. Parquet di penyimpanan berkas (gaya data lake) dengan dua zona, raw dan clean. Alasan: skema tabular tetap, beban kerja baca-berat berupa agregasi, Parquet kolumnar efisien untuk scan beberapa kolom, dan tidak perlu biaya ETL. NoSQL dan streaming tidak diimplementasikan karena tidak ada kebutuhan akses per-key atau aliran data.

Pipeline data: sumber → ingestion → storage → processing → output

4. Ingestion dan profiling data mentah

Data dibaca dengan *spark.read.parquet* (PySpark 4.2.0, Python 3.13.1, driver 4 GB, 8 shuffle partitions, 16 core, Windows 11; seed 42). Skema, jumlah baris, jumlah partisi, dan lima baris contoh ditampilkan di notebook (bagian 3); data taksi tidak memuat identitas pribadi.

Statistik dan nilai tidak valid. Median jarak 1,81 mil (p99 19,53; p99,9 30,0; maksimum 322.576); median fare $16,94 (p99 $85,69; p99,9 $151,72; rentang -$1.377,10 sampai $2.157,60); median durasi 14,6 menit (p99 79,85; p99,9 131,07). Tip minimum -$96,50. Tidak ada baris duplikat penuh. Pickup berkisar 30 November 20:48 sampai 31 Desember 23:59; 9 baris berada di luar Desember.

Missing values. Lima kolom (*passenger_count, RatecodeID, store_and_fwd_flag, congestion_surcharge, Airport_fee*) masing-masing null pada 1.195.482 baris (27,77%). Pada baris yang sama kelimanya null, dan seluruhnya berkode *payment_type = 0*; hubungan berlaku dua arah (kode 0 selalu null, kode 1-4 tidak pernah). Null ini **struktural**: satu segmen dengan pencatatan berbeda (kode 0 didefinisikan sebagai Flex Fare pada dokumentasi TLC), bukan data hilang acak.

VendorID	Total baris	Null passenger_count	Persen null
1	825.421	147.581	17,88%
2	3.417.640	1.043.372	30,53%
6	4.529	4.529	100%
7	57.416	0	0%

Perbedaan persen antar vendor mengikuti seberapa banyak tiap vendor mencatat kode 0, bukan sifat vendor itu sendiri. Segmen null memiliki rata-rata tip $0,48 (segmen normal $3,73). Dugaan awal bahwa fare segmen ini tidak mengikuti argometer **tidak didukung**: median fare per mil segmen null 7,48 dan segmen normal 6,84 (jarak 1-100 mil). Cara harga segmen ini dibentuk belum dapat disimpulkan. Pada perjalanan > 10

mil (data mentah) komposisi kode tarif: standar 33,93%, JFK 27,85%, segmen null 16,60%, kode 99 13,65%.

5. Preprocessing dan validasi kualitas data

Aturan validasi memakai ambang yang sama untuk audit dan cleaning. Alasan ambang (persentil bagian 4): jarak 0,1-100 mil (p99,9 30 mil; 100 mil membuang nilai mustahil tanpa memangkas perjalanan bandara yang sah, 0,1 mil membuang perjalanan hampir tak bergerak); durasi 1-180 menit (p99,9 131 menit); fare $3-$300 (biaya awal TLC $3,00; $300 kira-kira dua kali p99,9). Ambang adalah keputusan analis dan sensitivitasnya belum diuji.

Aturan	Pelanggaran individual	% dari mentah	Sisa kumulatif	Dibuang di tahap
Pickup dan dropoff tidak null	0	0,00	4.305.006	0
Pickup dalam Desember 2025	9	0,00	4.304.997	9
Dropoff setelah pickup	58.021	1,35	4.246.976	58.021
Durasi 1-180 menit	107.294	2,49	4.197.703	49.273
Jarak 0,1-100 mil	195.234	4,54	4.048.880	148.823
Fare 3-300 USD	55.335	1,29	4.001.723	47.157
Tip tidak negatif	78	0,00	4.001.723	0
Zona jemput/antar 1-263	32.278	0,75	3.973.407	28.316
Penumpang 1-6 (atau null struktural)	7	0,00	3.973.404	3

Pelanggaran individual tidak boleh dijumlahkan karena satu baris dapat melanggar lebih dari satu aturan; kolom kumulatifmengikuti urutan aturan.

Tindakan lain. (a) *passenger_count*: null struktural (1.195.482 baris) tidak diimputasi karena akan menciptakan data yang tidak ada; baris ditandai *segmen_null_pc = 1* dan kolom ini tidak dipakai sebagai fitur model utama. Nilai 0 (18.827 baris, 0,44%) dianggap salah input dan diimputasi modus (1), ditandai *passenger_imputed*. (b) Deduplikasi: 3.973.404 → 3.973.404 (0 dibuang). (c) Fitur turunan: jam jemput, hari, *kelompok_tarif*, serta tip% terhadap fare dan terhadap tagihan sebelum tip (di-cap 100%; 4.082 baris melampaui 100% terhadap fare). (d) Vendor 7 keluar dari data bersih karena dropoff sama dengan pickup (selisih 0 detik pada seluruh 57.416 baris), sekitar

99% dari pelanggaran urutan waktu.

Quality checks setelah transformasi (9, semua lulus): tidak ada null pada kolom kunci; tidak ada duplikat; jarak dalam rentang sah; fare dalam rentang sah; penumpang 1-6 bila tercatat; null *passenger_count* hanya di segmen struktural; dropoff setelah pickup; seluruh pickup di Desember 2025; tip% dalam [0, 100] dan skema sesuai. **Retensi akhir 3.973.404 / 4.305.006 = 92,30%.** Dari data bersih, 2.681.317 baris (67,48%) adalah tarif standar (RatecodeID 1) dan 1.053.503 (26,51%) segmen null.



Gambar 1. Sisa baris setelah tiap tahap cleaning. Sumber: agregasi Spark satu pass atas data mentah (notebook bagian 5.2).

6. Analisis PySpark DataFrame API dan Spark SQL

Operasi yang dipakai: filter dan select, groupBy/agregasi, kolom turunan, join (lookup zona, di-broadcast), ordering, dan window (share per kelompok). Q1, Q2, dan Q5 dijawab dengan DataFrame API dan Spark SQL; hasil Q1 dan Q2 diverifikasi sama antar keduanya.

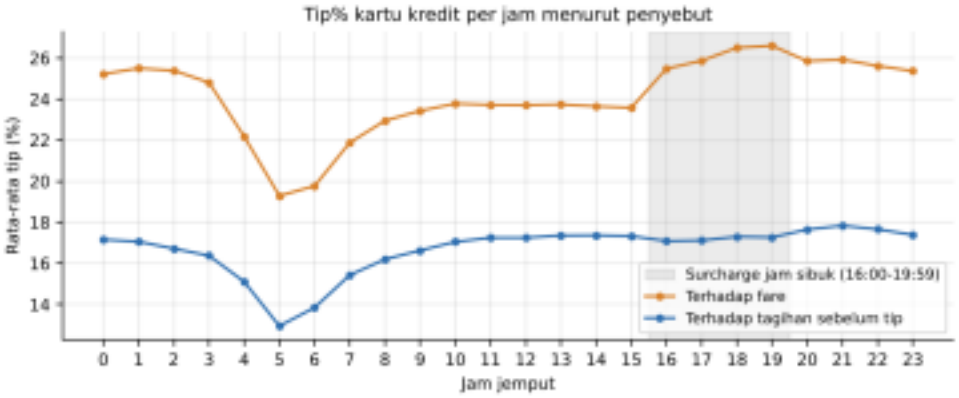
6.1 Q1: pola tip per hari dan jam

Hanya kartu kredit (*payment_type = 1*): 2.515.173 trip (63,3% data bersih), karena tip tunai tercatat nol. Tip% dihitung terhadap tagihan sebelum tip, di-cap 100%. Rata-rata keseluruhan 17,13% (terhadap fare: 24,69%). Slot dengan kurang dari 500 trip dibuang.

Slot	Trip	Rata-rata tip%	Median tip%	CI 95% (±)
Senin 21:00	22.021	18,09	20,0	0,09
Selasa 21:00	25.870	18,04	20,0	0,09
Rabu 21:00	26.069	17,94	20,0	0,09
Selasa 22:00	20.938	17,93	20,0	0,10
Kamis 21:00	23.835	17,91	20,0	0,10

Lima slot teratas seluruhnya Senin-Kamis 21:00-22:59, tetapi selisih peringkat 1 dan 5 hanya sekitar 0,2 poin persen, intervalnya tumpang tindih, dan median kelimanya identik. Keunggulan atas rata-rata sekitar 1 poin persen. Catatan: interval

mengasumsikan trip independen dan peringkat 1 dipilih dari 168 slot sehingga cenderung melebih-lebihkan. Terhadap fare, tip% hari kerja naik dari 23,39% (15:00) ke 25,96% (16:00) sedangkan akhir pekan tidak; terhadap tagihan sebelum tip lonjakan itu hilang. Karena surcharge jam sibuk $2,50 hanya berlaku hari kerja, lonjakan terhadap fare sebagian besar artefak penyebut, bukan perubahan perilaku penumpang.



Gambar 2. Rata-rata tip% kartu kredit per jam menurut dua penyebut. Sumber: agregasi Spark groupBy(pickup_hour) atas payment_type = 1.

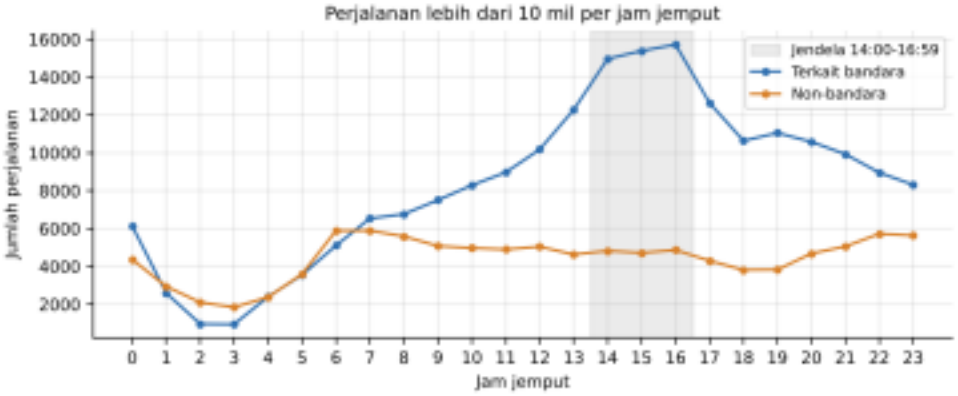
6.2 Q2: tujuan perjalanan jauh (> 10 mil) pukul 14:00-16:59

Apakah jam itu puncak? Sebagian. Tiga jam teratas menurut volume perjalanan jauh adalah 16:00 (20.585), 15:00 (20.106), dan 14:00 (19.791); ketiganya memuat 19,7% perjalanan jauh (12,5% jika merata), tetapi puncaknya landai (jam 17:00 dan 13:00 hanya sekitar 15% lebih rendah). Dari 60.482 perjalanan jauh di jendela ini, komposisi kelompok tarif: JFK tarif tetap 36,82%, standar 34,10%, lainnya (kode 3-6, 99) 22,01%, segmen null 7,07%. Karena itu hasil dipecah per kelompok; tabel gabungan hanya pembanding.

Kelompok tarif	Tujuan teratas	Share dalam kelompok
JFK tarif tetap (2)	JFK Airport	23,08% (fare rata-rata tepat $70,00)
Standar (1)	LaGuardia Airport	15,71% (fare rata-rata $54,41)
Lainnya (3-6, 99)	Newark Airport	18,70% (fare rata-rata $105,46)
Segmen null	JFK Airport	18,56% (fare rata-rata $78,31, bukan tarif tetap)
Gabungan (pembanding)	JFK 11,91% · LaGuardia 6,04% · Times Sq 4,48% · Newark 4,33%	10 tujuan teratas ≈ 38%

Tujuan tersebar, rute terkonsentrasi di bandara. Tidak ada tujuan yang melebihi 12%, tetapi 76,17% perjalanan jauh di jendela ini berasal dari atau menuju bandara; 55,06% berawal di bandara (JFK saja 41,99%, 25.395 trip; LaGuardia 13,07%).

Perjalanan jauh terkait bandara memuncak pada 14:00-16:59 (22,99% volumenya di jendela, ≈ 1,84 kali pembagian merata), sedangkan perjalanan non-bandara hampir datar pada siang-sore (13,51%, ≈ 1,08 kali) dan puncaknya pagi (5.891 pada 07:00). Jadi puncak sore adalah efek rute bandara. Pembatasan pada *RatecodeID = 1* akan membuat LaGuardia tampak sebagai tujuan utama padahal pada seluruh perjalanan jauh tujuan teratas adalah JFK.



Gambar 3. Perjalanan lebih dari 10 mil per jam jemput, terkait bandara (zona 1, 132, 138) vs non-bandara. Sumber: Spark groupBy atas data bersih.

6.3 Q5: konsistensi *extra* dan *cbd_congestion_fee*

Menurut aturan TLC, *extra* yang diharapkan adalah 0, $1,00 (malam 20:00-06:00), atau $2,50 (jam sibuk hari kerja 16:00-20:00). Nilai itu mencakup 84,99% data bersih dan 74,57% pada segmen normal. Dua penyimpangan menonjol. (1) Pada segmen null, *extra* bernilai 0 di 99,23% baris. (2) Vendor 1 tampak memasukkan komponen lain ke *extra*: pada 375.705 perjalanan *extra* melebihi harapan sebesar 3,25 dan pada 108.014 sebesar 2,50, dan jumlah kolom biaya melampaui *total_amount* persis sebesar kelebihan itu; pada Vendor 2 kecocokan ≥ 99,7%. Mengurangi *congestion_surcharge*, *Airport_fee*, dan *cbd_congestion_fee* dari *extra* Vendor 1 menaikkan kecocokan dengan aturan waktu dari 14,84% menjadi 90,31% (pada Vendor 2 koreksi yang sama menurunkannya dari 91,86% ke 3,89%). Karena itu *extra* tidak dapat dibaca tanpa memisahkan vendor, dan *total_amount* lebih andal daripada penjumlahan kolom; sekitar 9,7% perjalanan Vendor 1 belum terjelaskan. *cbd_congestion_fee* hanya bernilai 0 (27,56%) atau 0,75 (72,44%), sesuai toll $0,75; muncul pada 78,61% perjalanan Manhattan ke Manhattan dan 1,07% pada perjalanan tanpa Manhattan (validasi kasar karena memakai borough, bukan batas Jl. 60).

6.4 Pengukuran waktu

Tiga operasi diukur dengan fungsi pencatat waktu yang sama (3 ulangan; dicatat run pertama, minimum, dan median): agregasi tip per slot dengan DataFrame API, agregasi yang sama dengan Spark SQL (keduanya di atas data ter-cache), dan agregasi per jam yang dimulai dari pembacaan Parquet bersih tanpa cache (mencakup I/O). Hasil berupa tabel pada notebook (bagian 6). Keterbatasan: cache membuat dua operasi pertama tidak mencakup I/O disk; cache berkas sistem operasi mempercepat ulangan kedua dan ketiga pada operasi ketiga; hanya 3 ulangan pada satu mesin (16 core, driver 4 GB); *collect()* ikut mengukur transfer hasil; selisih DataFrame API dan Spark SQL kecil karena keduanya dikompilasi ke rencana eksekusi yang setara.

7. Pemodelan prediksi fare (Q3)

Desain. Target *fare_amount*. Model hanya untuk tarif argo standar (RatecodeID 1) karena tarif tetap JFK tidak dihitung dari jarak dan durasi; ini keputusan berbasis aturan tarif, bukan upaya menurunkan galat, dan dampaknya diukur eksplisit. Split 80/20 dengan seed 42 sebelum pelatihan (50% data), *RatecodeID* hanya untuk memilih subset, bukan fitur (tanpa leakage). Fitur *post-trip*: jarak, durasi, jam; *pre-trip*: jarak, jam, hari (jarak dianggap estimasi rute). *passenger_count* bukan fitur utama karena null pada segmen struktural; kontribusinya diuji terpisah. Pembanding: baseline rata-rata dan regresi linear; Random Forest 30 pohon, kedalaman 8, tanpa tuning. Test set standar: 268.296 perjalanan.

Model	**Fitur**	**RMSE**	**MAE**	**R^2**	**RMSE relatif**
Baseline rata-rata	-	$12,62	$8,83	0,000	73,3%
Regresi linear	post-trip	$1,34	$0,76	0,989	7,8%
Random Forest	post-trip	$2,72	$1,11	0,954	15,8%
Regresi linear	pre-trip	$4,69	$3,35	0,862	27,2%
Random Forest	pre-trip	$5,47	$3,67	0,812	31,7%

Tabel 1. Model dilatih dan diuji pada tarif standar. Sumber: bagian 7 notebook.

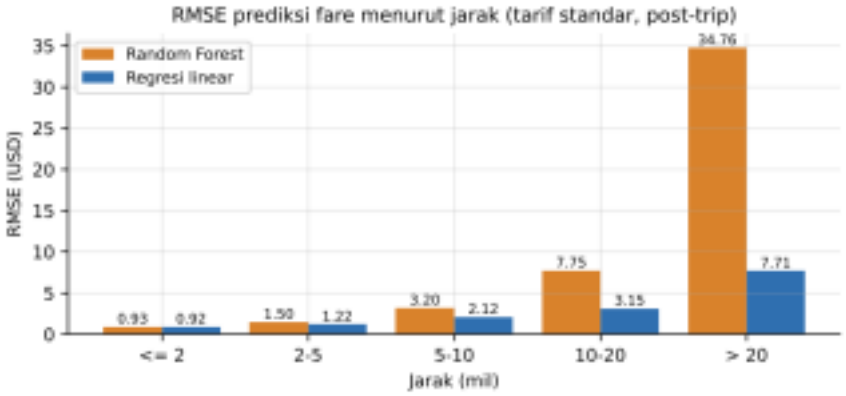
Hasil. Regresi linear post-trip memberi galat sekitar setengah Random Forest; hubungan fare dengan jarak dan durasi hampir linear sesuai struktur argometer. Koefisien: $2,44 per mil, $0,54 per menit, intercept $2,34 (lebih kecil daripada tarif TLC $3,50 per mil atau $0,70 per menit, konsisten dengan aturan bahwa

salah satu tarif berlaku pada tiap bagian perjalanan; dugaan, belum diuji). Tanpa durasi (pre-trip) RMSE linear naik 3,5 kali, dari $1,34 menjadi $4,69. Galat absolut Random Forest: median $0,59, p90 $2,04, p99 $9,75.

Dilatih pada	**RMSE regresi linear**	**RMSE Random Forest**
Semua kode tarif	$2,97	$3,27
Tanpa segmen null	$2,77	$2,49
Hanya RatecodeID 1	$1,34	$2,72

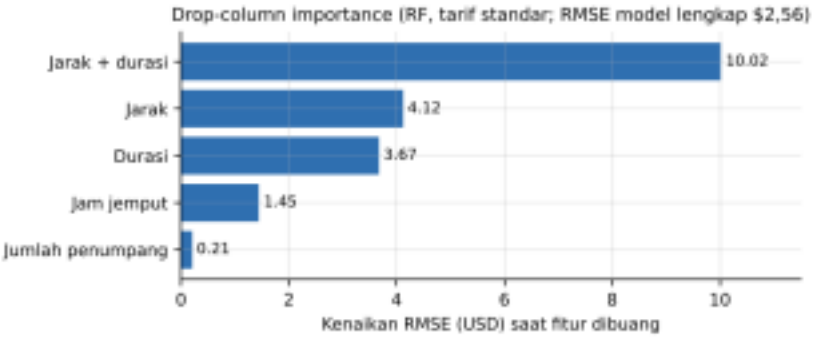
Tabel 2. Dampak ruang lingkup data, diuji pada test standar yang sama. Pada Random Forest efeknya tidak konsisten dan selisih kecil belum dapat dibedakan dari variasi acak (satu seed).

Di luar ruang lingkup model gagal: pada segmen null (*payment_type* = *0*) RMSE $12,2-14,4 dan R^2 0,12-0,37; pada perjalanan JFK tarif tetap (fare hampir seragam $70) R^2 tidak bermakna dan RMSE terbaik $8,22.



Gambar 4. RMSE menurut jarak. Perjalanan > 20 mil hanya 0,3% data uji tetapi menyumbang 43,7% galat kuadrat Random Forest (bias -$32,53 per perjalanan; regresi linear -$3,52). Sumber: prediksi test standar.

Faktor penentu (drop-column importance, RF 20 pohon, 30% data latih). Membuang jarak dan durasi sekaligus menaikkan RMSE $10,02 (hampir setara baseline); membuang jarak saja +$4,12 dan durasi saja +$3,67. Jumlah kenaikan individual ($7,79) lebih kecil daripada saat dibuang bersamaan, tanda informasi yang tumpang tindih (korelasi jarak-durasi 0,696; jarak-fare 0,928; durasi-fare 0,903). Jam jemput menambah $1,45 walaupun koefisien linearnya hampir nol (hubungan non-linear, mungkin lewat lalu lintas; dugaan). Jumlah penumpang hanya $0,21, belum dapat dibedakan dari variasi acak.



Gambar 5. Kenaikan RMSE saat fitur dibuang. Sumber: drop-column importance, satu seed.

8. Temuan, keterbatasan, dan rekomendasi

Temuan utama

- **Anomali data bersumber dari sedikit sumber sistematis.** Segmen *payment_type* = *0* menyumbang seluruh null, dan Vendor 7 mencatat dropoff sama dengan pickup. Retensi setelah cleaning 92,30% (Gambar 1, tabel audit).
- **Tip hampir seragam menurut waktu.** Rata-rata 17,13%; slot terbaik hanya sekitar 1 poin persen lebih tinggi dan tidak dapat dibedakan dari peringkat 5; lonjakan terhadap fare pada jam sibuk adalah artefak penyebut (Gambar 2).
- **Perjalanan jauh sore hari adalah perjalanan bandara** (76,17% terkait bandara,

41,99% berawal di JFK); perjalanan non-bandara tidak memuncak sore (Gambar 3).

- **Tarif standar hampir sepenuhnya ditentukan jarak dan durasi.** Regresi linear RMSE $1,34 mengalahkan Random Forest $2,72; kegagalan Random Forest terkonsentrasi pada perjalanan > 20 mil (Tabel 1, Gambar 4-5).
- **Pencatatan biaya tidak seragam antar vendor.** *extra* Vendor 1 memuat komponen lain, sehingga *total_amount* lebih andal daripada penjumlahan kolom (bagian 6.3).

Keterbatasan

• Hanya Desember 2025 (musim libur); pola tip dan perjalanan bandara bulan lain dapat berbeda. • Q1 hanya kartu kredit; rata-rata tip% mencampur proporsi trip tanpa tip dengan besar tip (proporsi tip nol belum dihitung); interval kepercayaan mengasumsikan trip independen dan tidak mengoreksi pemilihan dari 168 slot.

• Pemodelan memakai satu split dan satu seed, 50% data, dan Random Forest tanpa tuning; selisih kecil antar model dan fitur tidak dapat diuji signifikansinya. Model hanya berlaku untuk tarif standar. • Bandara didefinisikan dengan tiga ID zona dan ambang 'jauh' 10 mil berdekatan dengan jarak bandara ke pusat kota; asal dan tujuan dianalisis terpisah. Ambang cleaning adalah keputusan analis tanpa uji sensitivitas.

• Belum terjelaskan: cara harga segmen *payment_type = 0* dibentuk, turunnya tip% pukul 04:00-07:00, dan sekitar 9,7% perjalanan Vendor 1 pada koreksi *extra*.

Rekomendasi

- **Pengemudi/armada:** perjalanan jauh sore hari terutama diperoleh di bandara, terutama JFK; apakah menunggu di sana menguntungkan tidak dapat disimpulkan karena waktu tunggu tidak tercatat. Jangan mengarahkan armada berdasarkan beda tip% antar slot teratas.
- **TLC/MTA:** *cbd_congestion_fee* konsisten dengan toll $0,75, tetapi pencatatan *extra* Vendor 1 dan dropoff Vendor 7 perlu diklarifikasi sebelum dipakai untuk evaluasi tarif.
- **Pengembang aplikasi tarif:** gunakan regresi linear untuk tarif argo standar (fitur pre-trip bila durasi belum diketahui) dan nyatakan batas pemakaian; jangan dipakai untuk tarif tetap JFK atau *payment_type = 0*.
- **Pekerjaan lanjutan:** tambah bulan lain, hitung proporsi tip nol, pasangkan asal-tujuan, uji sensitivitas ambang cleaning.

9. Referensi

• NYC Taxi and Limousine Commission. *TLC Trip Record Data*. https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page (diakses 1 November 2026). • NYC Taxi and Limousine Commission. *Yellow Taxi Trip Records Data Dictionary* (tersedia pada halaman Trip Record Data).

• NYC Taxi and Limousine Commission. *Taxi Fare*. https://www.nyc.gov/site/tlc/passengers/taxi-fare.page (aturan tarif, surcharge).

• NYC Open Data. *Terms of Use* (ketentuan penggunaan data publik Kota New York).

• Apache Spark. *Spark SQL, DataFrames and MLlib documentation*. https://spark.apache.org/docs/latest/

Lampiran A. Reproduksibilitas

Notebook *Proyek_MidTerm.ipynb* berurutan dan dijalankan dari atas ke bawah (Restart and Run All). Versi, konfigurasi, seed (42), parameter (*ML_FRACTION* 0,5; *IMP_FRACTION* 0,3; *MIN_TRIPS_SLOT* 500), cara memperoleh data, struktur folder, dan keterbatasan reproduksi dijelaskan pada *README.md*. Dataset penuh tidak dilampirkan.

Lampiran B. Peran dan deklarasi penggunaan AI generatif

Proyek kelompok: Muhammad Rifky Alfajri mengerjakan seluruh bagian. Claude (Anthropic) dipakai sebagai pendamping untuk merevisi teks notebook, menambah diagram arsitektur, pengukuran waktu, visualisasi, dan bagian temuan, serta menyusun README. Kode dan kesimpulan diverifikasi penulis dengan menjalankan notebook dan mencocokkannya dengan output.