ANALISIS BIG DATA

4,3 jt

NYC Yellow Taxi Desember 2025 dengan PySpark

Struktur tarif, perilaku tip, pola perjalanan jauh, dan prediksi tarif argo standar

Muhammad Rifky Alfajri · 103012430036 · BS1 IF 48 GAB01
Big Data and Artificial Intelligence · Midterm Project · S1 Informatika, Telkom University

Satu pertanyaan, lima analisis, satu bulan data

Pertanyaan utama
Bagaimana struktur tarif, perilaku tip, dan pola perjalanan jauh, dan seberapa jauh tarif argo standar dapat diprediksi dibanding baseline sederhana?

Pertanyaan: pengemudi/armada (Q1, Q2), TLC/MTA (Q5), pengembang aplikasi tarif (Q3)

5V: volume menengah-besar, variety rendah, velocity rendah (batch bulanan), veracity menengah, value tinggi

4.305.006
baris mentah

20 kolom
73,7 MB Parquet

16
partisi Spark

Q1-Q5
tip, perjalanan jauh, model, kualitas, biaya



92,30% data lolos cleaning; null bersifat struktural

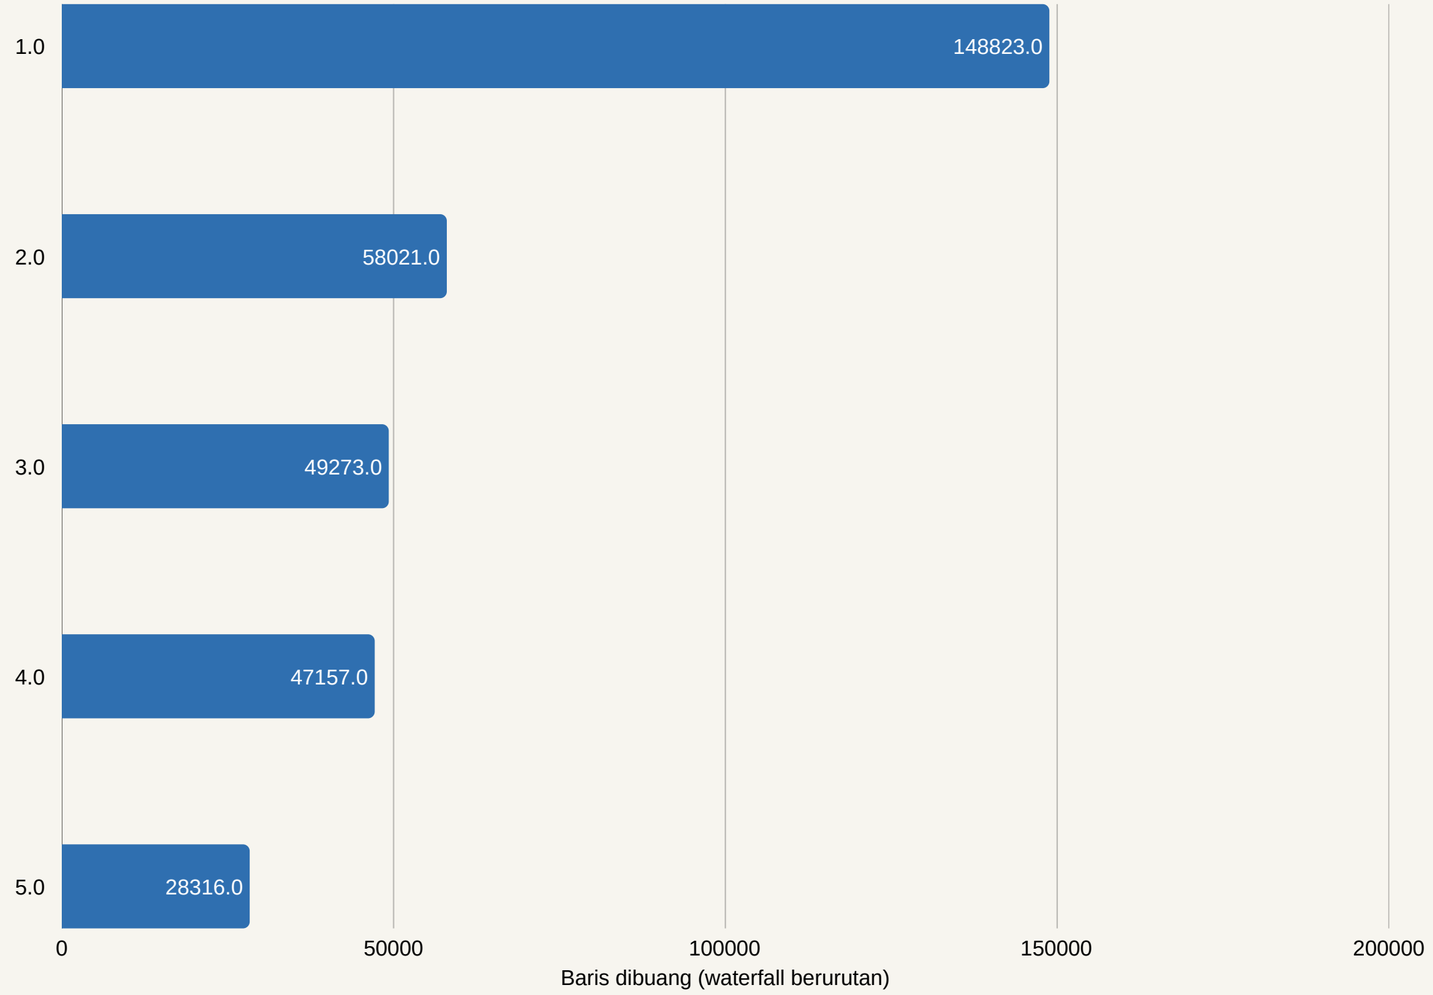
92,30%

3.973.404 dari 4.305.006 baris

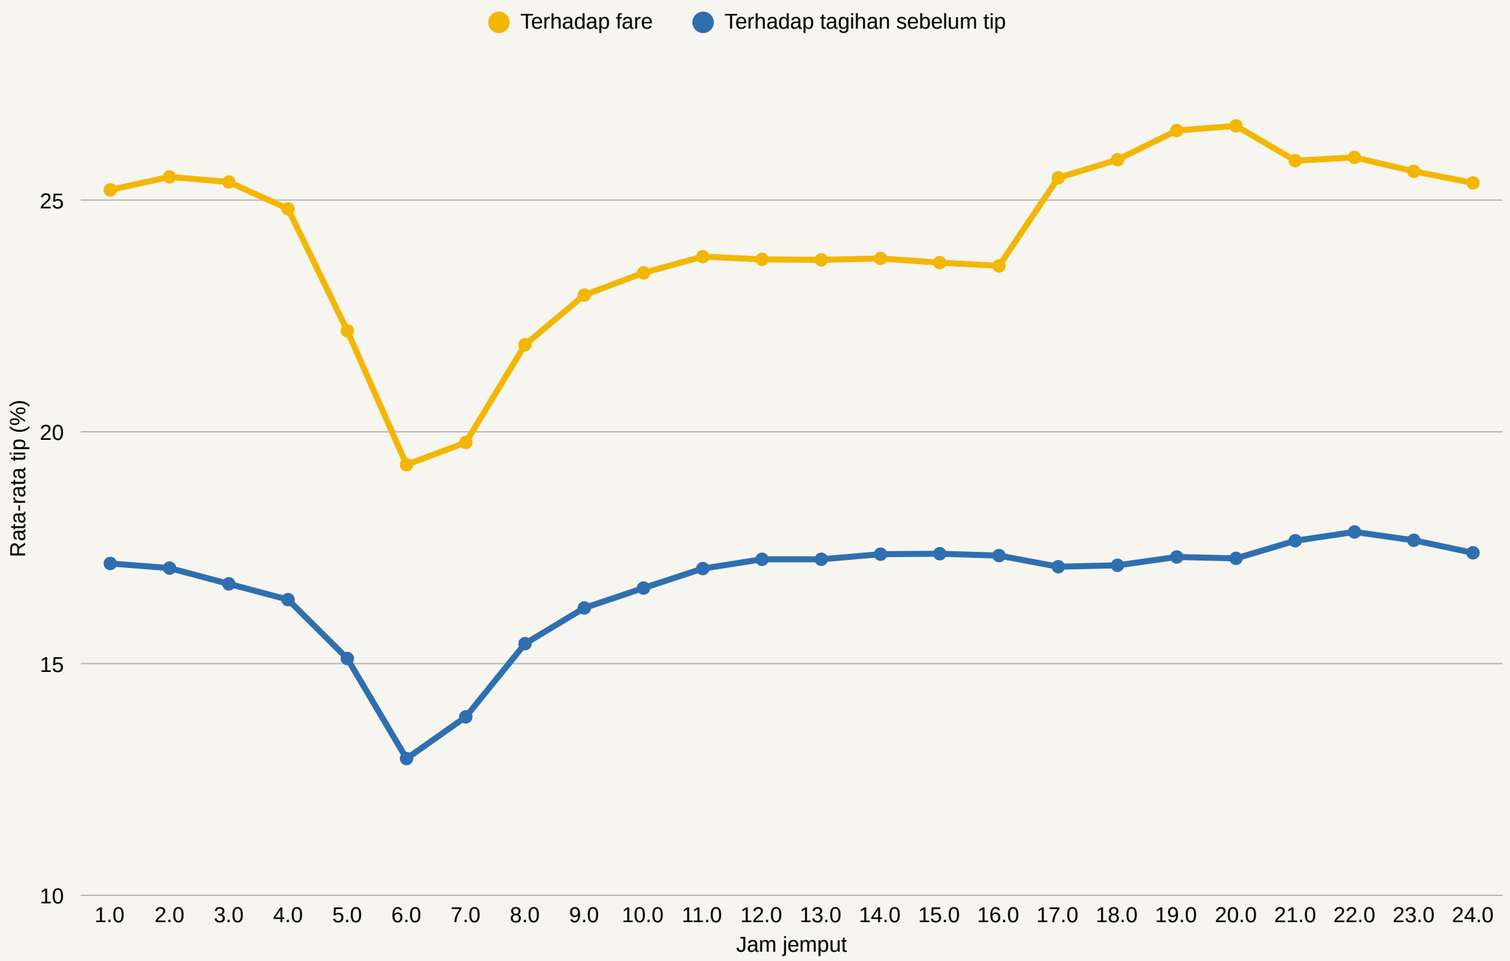
27,77% null

seluruhnya payment_type = 0 (Flex Fare), dua arah 100%

Aturan jarak membuang paling banyak. Vendor 7 mencatat dropoff = pickup pada 57.416 baris (99% pelanggaran urutan waktu). NULL passenger_count tidak diimputasi; nilai 0 (0,44%) diimputasi modus.



Q1: lonjakan tip di jam sibuk adalah artefak penyebut



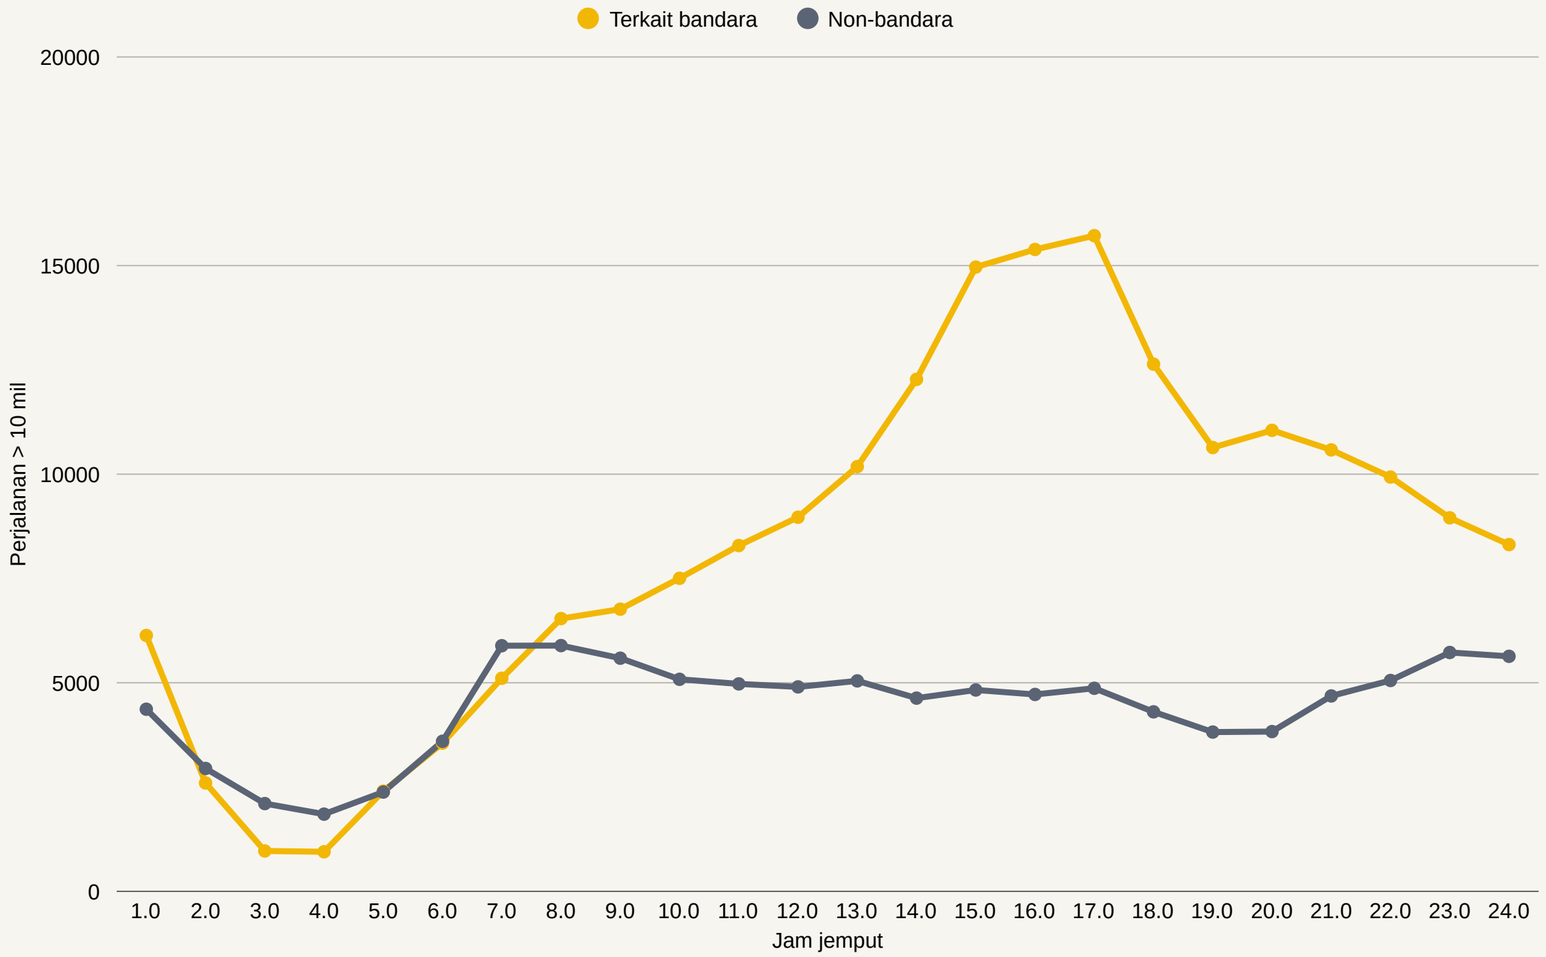
17,13%

rata-rata tip kartu kredit terhadap tagihan sebelum tip (24,69% terhadap fare)

Hari kerja 15:00 ke 16:00: 23,39% ke 25,96% terhadap fare, akhir pekan tidak naik. Surcharge jam sibuk $2,50 hanya hari kerja.

Slot teratas: Senin-Kamis 21:00-22:59 (18,09% vs 17,91%). Tidak dapat dibedakan secara statistik.

Q2: perjalanan jauh sore hari adalah rute bandara



76,17%

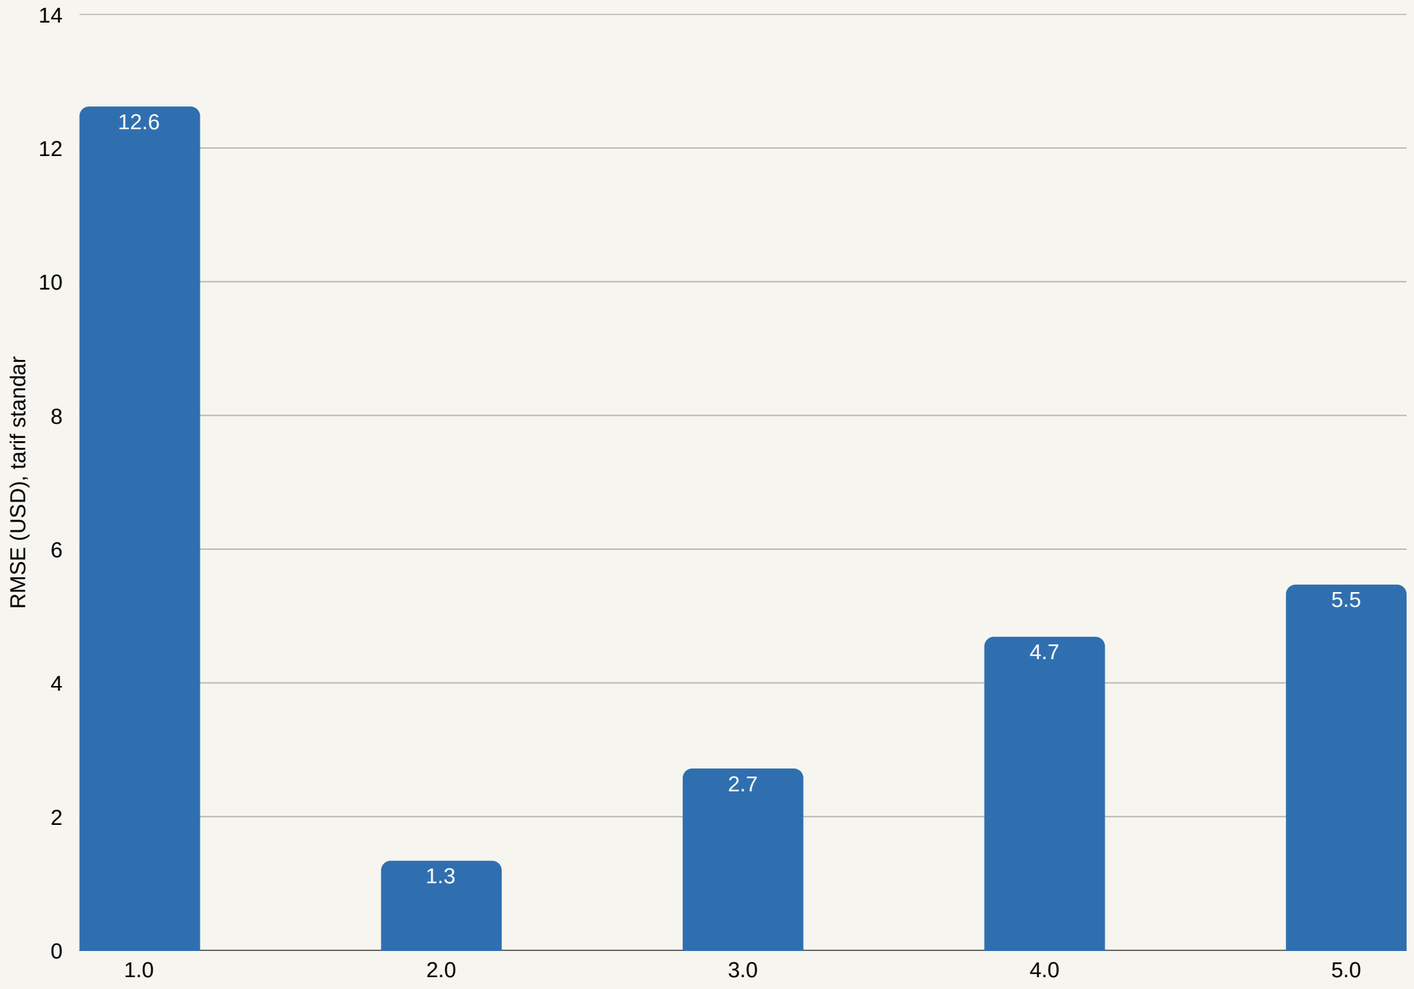
perjalanan jauh 14:00-16:59 terkait bandara

55,06%

berawal di bandara (JFK saja 41,99%)

Tujuan tersebar: terbesar JFK hanya 11,91%. Hasil dipecah per kelompok tarif karena filter RatecodeID = 1 hanya menyisakan 34,10% perjalanan jauh dan membuat LaGuardia tampak dominan.

Q3: regresi linear mengalahkan Random Forest



R^2 0,989

regresi linear post-trip (RMSE $1,34) vs Random Forest $2,72

Perjalanan > 20 mil: 0,3% data uji, 43,7% galat kuadrat RF.

Drop-column: jarak + durasi +$10,02; jarak +$4,12; durasi +$3,67; jam +$1,45; penumpang +$0,21.

Model hanya berlaku untuk tarif standar.

Kesimpulan, keterbatasan, dan rekomendasi

Temuan

- Retensi 92,30%; null struktural (payment_type 0)
- Tip seragam ~17%; lonjakan jam sibuk artefak penyebut
- Perjalanan jauh sore = rute bandara (76,17%)
- Tarif standar ditentukan jarak dan durasi; linear RMSE $1,34
- extra Vendor 1 memuat komponen lain

Keterbatasan

- Hanya Desember 2025 (musim libur)
- Satu split dan seed; RF tanpa tuning
- Ambang cleaning belum diuji sensitivitasnya
- Harga segmen payment_type 0 belum terjelaskan

Rekomendasi

- Armada: perjalanan jauh sore terutama di bandara; waktu tunggu perlu data
- Jangan mengarahkan armada dari beda tip% antar slot
- Aplikasi tarif: pakai regresi linear, hanya untuk tarif standar
- Lanjutan: tambah bulan, pasangkan asal-tujuan

Terima kasih